

Improving Student Wellbeing

Strategies to Reduce Depression on Campus




Presented by:

Nicolas Gabriel Siahaan | Alya Hamidah

Data Science Department

Depression? Why?

Is it really necessary?



Terjadi **peningkatan kasus bunuh diri** pada periode Januari-Juli 2023 sebanyak **31,75%** dibandingkan dengan periode yang sama tahun sebelumnya


College? New life?

Is it really that scary?



Meningkatnya kasus depresi dan kasus bunuh diri di kalangan mahasiswa

Sumber: [Kompasiana.com](https://kompasiana.com)



Sumber: fkm.unair.ac.id

Tabel 1. Kondisi Kesehatan Mental Mahasiswa Berdasarkan Skor SRQ-20

Tingkat Skor SRQ-20	Jumlah Responden	Persentase
14 - 20 (Berat)	267	21.9%
9 - 13 (Sedang)	530	43.5%
0 - 8 (Ringan)	419	34.4%
Total	1219	100%

Tabel 2. Kondisi Kesehatan Mental Berdasarkan Persepsi Responden

Tingkat Kerentanan (Persepsi)	Jumlah Responden	Persentase
Berat	46	3.8%
Sedang	684	56.1%
Ringan	489	40.1%
Total	1219	100%

Berdasarkan survey kesehatan mental oleh UNESA menunjukkan total **63,5% mahasiswa** dengan tingkat **depresi sedang hingga berat**

Sumber: smccu.unesa.id

Still, why?
Is it really matters?

Mencapai **INDONESIA EMAS** 2045

Tingkatan **masa produktif** tertinggi

Kualitas **hidup** meningkat

It is REAL!

so, what could be the triggers?

The Possible Triggers

what could make it happened?



Transition



Away from home



Overthinking

Goal

Mereduksi tingkat depresi
di kalangan mahasiswa

dengan cara

Prediksi dini kondisi
mental seseorang



Memastikan kehidupan yang sehat dan meningkatkan kesejahteraan bagi semua orang di segala usia:
Mencegah peningkatan jumlah mahasiswa depresi dengan prediksi dini



Benefit

what would we get?

Pencegahan Dini dan Dukungan Kesehatan Mental

Mengurangi Stigma Kesehatan Mental

Meningkatkan Kualitas Hidup Mahasiswa

Data Overview

SUMBER

[Link Kaggle](#)
Student Depression Dataset

CAKUPAN

Dataset berasal dari India
dengan total 52 kota

FITUR

Dataset ini memiliki 17 fitur dan 1 target. Fitur yang dimiliki yaitu informasi demografis, kinerja akademik, kebiasaan gaya hidup, riwayat kesehatan mental, dan respons terhadap skala depresi standar.

PERAN

Sebagai data pelatihan untuk membentuk model machine learning yang dapat dan memprediksi apakah seseorang depresi atau tidak

Features

- ID
- Age
- Gender
- City
- CGPA
- Sleep duration
- Profession
- Work pressure
- Academic pressure
- Study satisfaction
- Job satisfaction
- Family history of mentall illness
- Dietary habits
- Degree
- Suicidal thoughts
- Work/study hours
- Financial stress
- Depression

Metric Evaluation

Recall

$$\frac{TP}{TP + FN}$$

- Memperkecil FN (False Negative)
- Imbalance dataset

Accuracy

$$\frac{\text{Correct predictions}}{\text{All predictions}}$$

Evaluasi kinerja model terhadap kebenaran prediksi

EDA & Data Visualization

All the steps:



Data Explore

Finding outliers, missing value, anomaly data



Business Question

Help stakeholders find solution




Data Visualization

Presenting data to answer business questions


What we found?




Terdapat beberapa **nilai tidak sesuai** di beberapa fitur



Terdapat **outlier** di salah satu fitur



Terdapat sedikit **nilai null** di salah satu fitur



Kolom target bersifat **Imbalanced**


```
[94] # Fitur dietary habits
counts = df['dietary_habits'].value_counts()
print(counts)
```

```
↩ dietary_habits
Unhealthy    10317
Moderate      9921
Healthy       7651
Others         12
Name: count, dtype: int64
```

```
[96] # Fitur sleep duration
counts = df['sleep_duration'].value_counts()
print(counts)
```

```
↩ sleep_duration
Less than 5 hours    8305
7-8 hours            7343
5-6 hours            6180
More than 8 hours    6043
Others                18
Name: count, dtype: int64
```

```
# Fitur degree
counts = df['degree'].value_counts()
print(counts)
```

```
↩ degree
Class 12    6079
B.Ed        1865
B.Com       1504
B.Arch      1476
BCA         1432
MSc         1189
B.Tech      1151
MCA         1041
M.Tech      1020
BHM         925
BSc         886
M.Ed        819
B.Pharm     809
M.Com       734
MBBS        696
BBA         696
LLB         670
BE          611
BA          597
M.Pharm     581
MD          572
MBA         561
MA          544
PhD         520
LLM         482
MHM         191
ME          185
Others       35
Name: count, dtype: int64
```

```
# Fitur city
counts = df['city'].value_counts()
print(counts)
```

```
city
Kalyan    1568


Faridabad    461
Saanvi        2
Bhavna        2
City           2
Harsha        2
Kibara        1
Nandini       1
Nalini        1
Mihir         1
Nalyan        1
M.Com         1
ME            1
Rashi         1
Gaurav        1
Reyansh       1
Harsh         1
Vaanya        1
Mira          1
Less than 5 Kalyan  1
3.0           1
Less Delhi    1
M.Tech        1
Khaziabad     1
Name: count, dtype: int64
```

Improper Value

Null-Value

	sdd_df.isna().sum()	
		0
	id	0
	Gender	0
	Age	0
	City	0
	Profession	0
	Academic Pressure	0
	Work Pressure	0
	CGPA	0
	Study Satisfaction	0
	Job Satisfaction	0
	Sleep Duration	0
	Dietary Habits	0
	Degree	0
	Have you ever had suicidal thoughts ?	0
	Work/Study Hours	0
	Financial Stress	3
	Family History of Mental Illness	0
	Depression	0

Imbalance Target



Outlier

Distribusi Umur

Age

18	1,211
19	1,099
20	1,574
21	1,163
22	699
23	1,042
24	1,503
25	1,078
26	662
27	880
28	1,301

29	1,095
30	469
31	683
32	646
33	735
34	398
35	2
36	1
38	2
39	2
41	1
42	2
43	1
46	1
48	1

Feature details

Before ...

ID

SLEEP DURATION

PROFESSION

WORK PRESSURE

AGE

ACADEMIC
PRESSURE

STUDY
SATISFACTION

JOB
SATISFACTION

FAMILY HISTORY

CGPA

DIETARY HABITS

DEGREE

SUICIDAL
THOUGHTS

WORK/STUDY
HOURS

GENDER

FINANCIAL
STRESS

CITY

DEPRESSION

(27901, 14)

Feature details

After ...

ID

SLEEP DURATION

PROFESSION

WORK PRESSURE

AGE

ACADEMIC
PRESSURE

STUDY
SATISFACTION

JOB
SATISFACTION

FAMILY HISTORY

CGPA

DIETARY HABITS

DEGREE

SUICIDAL
THOUGHTS

WORK/STUDY
HOURS

GENDER

FINANCIAL
STRESS

CITY


DEPRESSION

(27767, 14)

How the depression distribution?

Bagaimana fitur-fitur yang ada dapat mempengaruhi kesehatan mental seseorang?






Demografi dan Geografi

Gender

Jumlah penderita depresi **pada laki-laki cenderung lebih tinggi** daripada perempuan

Namun, jika dilihat dari **rasio penderita depresi** dan yang tidak menderita depresi, baik laki-laki maupun perempuan **memiliki rasio yang tidak jauh berbeda**

Jumlah Penderita dan Bukan Penderita Depresi Berdasarkan Gender



Umur

Umur diatas 34 memiliki jumlah yang **sangat sedikit**


Distribusi Umur

Age

18	1,211
19	1,099
20	1,574
21	1,163
22	699
23	1,042
24	1,503
25	1,078
26	662
27	880
28	1,301


29	1,095
30	469
31	683
32	646
33	735
34	398
35	2
36	1
38	2
39	2
41	1
42	2
43	1
46	1
48	1

Jumlah Penderita Depresi dan Bukan Penderita Depresi



Umur


Jumlah Penderita Depresi Berdasarkan Gender



Umur

Pada rentang umur 18 – 34 memiliki jumlah **penderita depresi** yang **cukup banyak** dengan **tren menurun**

Jumlah Bukan Penderita Depresi Berdasarkan Gender




Umur

Pada rentang umur 18 – 34 memiliki jumlah **bukan penderita depresi** yang **cukup banyak** dengan **tren menaik**

Kota

Tidak ditemukan pola tertentu dari penderita depresi kota yang telah disortir berdasarkan tingkat ekonomi (rendah < sedang < tinggi)

Jumlah Penderita Depresi Sesuai dengan Kota (Berdasarkan tingkat ekonomi)






Akademik

CGPA

Distribusi Jumlah Penderita Depresi Pada CGPA




Tidak terlihat pola jumlah penderita depresi pada CGPA yang dapat digunakan

CGPA

Jumlah **penderita depresi terbanyak** berdasarkan CGPA memiliki **CGPA yang tinggi**

5 CGPA dengan Jumlah Penderita Depresi Terbanyak




Tekanan Akademik

Jumlah penderita depresi berdasarkan tekanan akademik mengalami kelonjakan

4 → 3911

5 → 5395

Jumlah Penderita dan Bukan Penderita Depresi Berdasarkan Tingkat Tekanan Akademik




Kepuasan Belajar


Jumlah penderita depresi berdasarkan tekanan kepuasan belajar mengalami penurunan

1 → 3834


2 → 3756

Jumlah Penderita dan Bukan Penderita Depresi Berdasarkan Tingkat Kepuasan Belajar






Durasi Belajar




Durasi Belajar

Semakin **lama durasi belajar**, semakin tinggi pula **jumlah penderita depresi**



Durasi Belajar

Dibandingkan dengan **jumlah penderita depresi**, jumlah yang **tidak menderita depresi jauh lebih sedikit**.



Degree

Tidak ditemukan pola jumlah penderita depresi **dari tingkatan pendidikan** (Class 12 < Bachelor < Master)




Kebiasaan Hidup

Pola Makan

Orang dengan **pola makan tidak sehat** lebih **rentan mengalami depresi**


Jumlah Penderita dan Bukan Penderita Depresi Berdasarkan Kebiasaan Pola Makan



Durasi Tidur

Orang dengan **durasi tidur kurang** lebih **rentan mengalami depresi**

Jumlah Penderita dan Bukan Penderita Depresi Berdasarkan Durasi Tidur





Ekonomi

Tekanan Finansial

Jumlah penderita depresi berdasarkan tekanan finansial mengalami kelonjakan

4 → 3974

5 → 5425

Jumlah Penderita dan Bukan Penderita Depresi Berdasarkan Tingkat Tekanan Finansial






Kesehatan Mental

Riwayat Penyakit Mental pada Keluarga

Riwayat penyakit mental pada keluarga **tidak memiliki dampak yang besar** terhadap jumlah penderita depresi.

Dapat dilihat pada jumlah penderita depresi, **jumlah yang memiliki riwayat** dengan yang **tidak memiliki riwayat tidak jauh berbeda**.


Jumlah Penderita dan Bukan Penderita Depresi Berdasarkan Riwayat Penyakit Mental Pada Keluarga



Keinginan Bunuh Diri

Keinginan untuk bunuh diri **memiliki dampak yang besar** terhadap penderita depresi.

Dapat dilihat pada jumlah penderita depresi, orang yang **memiliki keinginan bunuh diri** dengan yang **tidak memiliki keinginan untuk bunuh diri** memiliki **jumlah yang jauh berbeda**.



Conclusion



TREN NAIK

Terdapat tren naik pada distribusi data:

- Tekanan Akademik
- Durasi Belajar
- Tekanan Finansial



TREN TURUN

Terdapat tren turun pada distribusi data:


- Kepuasan Belajar



SIGNIFIKAN

Terdapat perbedaan yang signifikan pada masing-masing tingkatan pada distribusi target:

- Durasi Tidur
- Pola Makan
- Suicidal Thoughts



Tidak Berpola

Terdapat fitur yang tidak memiliki pola pada distribusi target di fitur tersebut:

- Gender
- City
- CGPA
- Degree

Preprocessing & Model Selection



Preprocessing

Handling imbalanced data, categorical data, scaling, and sampling

Feature Selection

Select feature that might give high impact for model

Training

Finding the best result after training

Advanced Preprocessing

What we do before model selection:

Binary Encoding

One-Hot Encoding

Ordinal Encoding

Binning

Scaling

Undersampling

Feature Selection

Binary Encoding

```
# Encoding untuk kolom suicidal_thoughts
df['suicidal_thoughts_bool'] = df['suicidal_thoughts'].map({'Yes': True, 'No': False})
```

```
# Menampilkan hasil encoding
counts = df['suicidal_thoughts_bool'].value_counts()
print(counts)
```

```
suicidal_thoughts_bool
True      17568
False     10199
Name: count, dtype: int64
```

```
# Encoding untuk kolom family_history
df['family_history_bool'] = df['family_history'].map({'Yes': True, 'No': False})
```

```
# Menampilkan hasil encoding
counts = df['family_history_bool'].value_counts()
print(counts)
```

```
family_history_bool
False     14323
True      13444
Name: count, dtype: int64
```


```
# Encoding untuk kolom gender
df['is_male'] = df['gender'].map({'Male': True, 'Female': False})
```

```
# Menampilkan hasil encoding
counts = df['is_male'].value_counts()
print(counts)
```


```
is_male
True      15472
False     12295
Name: count, dtype: int64
```

Binning

Jumlah Penderita Depresi Berdasarkan Gender



Jumlah Bukan Penderita Depresi Berdasarkan Gender



Binning

```
# Binning umur dengan rentang 18-34 dan 35-59
bins = [18, 34, 59]
labels = ['18-34', '35-59']
df['kategori_umur'] = pd.cut(df['age'], bins=bins, labels=labels, right=True, include_lowest=True)
```

```
# Binning umur dengan rentang 18-27, 28-37, 38-59
bins = [18, 27, 37, 59]
labels = ['18-27', '28-37', '38-59']
df['kategori_umur_2'] = pd.cut(df['age'], bins=bins, labels=labels, right=True, include_lowest=True)
```

```
# Menampilkan hasil binning
print(df[['age', 'kategori_umur', 'kategori_umur_2']].tail(10))
```

	age	kategori_umur	kategori_umur_2
27891	28.0	18-34	28-37
27892	20.0	18-34	18-27
27893	24.0	18-34	18-27
27894	23.0	18-34	18-27
27895	31.0	18-34	28-37
27896	27.0	18-34	18-27
27897	27.0	18-34	18-27
27898	31.0	18-34	28-37
27899	18.0	18-34	18-27
27900	27.0	18-34	18-27

```
# Encoding untuk kolom degree
```

```
# Function untuk perubahan degree
```

```
def s_berapa(x):
    if x=='Class 12':
        return 0
    elif x[0] == 'B':
        return 1
    elif x[0] == 'M':
        return 2
    elif x=='LLM':
        return 2
    elif x=='LLB':
        return 1
    else:
        return 0
```

```
# Pengaplikasian function
```

```
df['nomor_degree'] = df['degree'].apply(s_berapa)
```

```
# Menampilkan hasil encoding
```

```
print(df[['degree', 'nomor_degree']].head())
```

	degree	nomor_degree
0	B.Pharm	1
1	BSc	1
2	BA	1
3	BCA	1
4	M.Tech	2

One-Hot Encoding

```
# One-hot encoding untuk 'kategori_umur'  
df = pd.get_dummies(df, columns=['kategori_umur'])
```

```
# One-hot encoding untuk 'kategori_umur_2'  
df = pd.get_dummies(df, columns=['kategori_umur_2'])
```


Ordinal Encoding

```
# Encoding untuk kolom dietary_habits

# Mapping kategori dietary_habits
dietary_mapping = {
    'Unhealthy': 1,
    'Moderate': 2,
    'Healthy': 3
}

# Pengaplikasian mapping
df['dietary_habits_encoded'] = df['dietary_habits'].map(dietary_mapping)

# Menampilkan hasil encoding
print(df[['dietary_habits', 'dietary_habits_encoded']].head())
```

	dietary_habits	dietary_habits_encoded
0	Healthy	3
1	Moderate	2
2	Healthy	3
3	Moderate	2
4	Moderate	2

Scaling

```
# min-max scaler  
from sklearn.preprocessing import MinMaxScaler  
  
scaler1 = MinMaxScaler(feature_range=(0, 1))  
minmax_data = scaler1.fit_transform(data_final)
```

```
# standard scaler  
scaler2 = StandardScaler()  
X_stand = scaler2.fit_transform(X)
```

Undersampling

```
# tokek links

# Import library
from imblearn.under_sampling import TomekLinks

# Pengaplikasian tokek links undersampling
tl = TomekLinks()
X_tomek, y_tomek = tl.fit_resample(X_resampled, y_resampled)
```

```
# random undersampling

# Import library
from imblearn.under_sampling import RandomUnderSampler

# Pengaplikasian random undersampling
rus = RandomUnderSampler(random_state=42)
X_random, y_random = rus.fit_resample(X_resampled, y_resampled)
```


Feature Selection

Mutual Information -> dependency

Banyaknya informasi dari satu variabel ke variabel lainnya

```
# mengambil 10 dari data yang tidak di undersampling  
n_undersampling_feat
```

```
['suicidal_thoughts_bool',  
 'academic_pressure',  
 'financial_stress',  
 'age',  
 'work_study_hours',  
 'dietary_habits_encoded',  
 'kategori_umur_28-37',  
 'kategori_umur_18-27',  
 'study_satisfaction',  
 'nomor_degree']
```

```
# mengambil 10 dari data yang di undersampling  
undersampling_feat
```

```
['suicidal_thoughts_bool',  
 'academic_pressure',  
 'financial_stress',  
 'age',  
 'work_study_hours',  
 'kategori_umur_28-37',  
 'kategori_umur_18-27',  
 'dietary_habits_encoded',  
 'study_satisfaction',  
 'nomor_degree']
```

Hasil Evaluasi Model

Logistic Regression

Linear SVM

Random Forest

XGBoost

Training dengan semua fitur

Logistic Regression	0.889
Linear SVM	0.891
Random Forest	0.882
XGBoost	0.883

Training
dengan
n=10
fitur

Logistic Regression	0.888
Linear SVM	0.889
Random Forest	0.866
XGBoost	0.881

Nilai n lain menghasilkan skor yang kurang lebih sama atau bahkan lebih buruk

Training
setelah
tuning
hyperpa
rameter

Logistic Regression	0.890
Linear SVM	0.890
Random Forest	0.889
XGBoost	0.860

Training dengan teknik voting

```
vt = VotingClassifier(estimators=[('lr', clf1), ('linear_svc', clf2), ('rf', clf3), ('xgb', clf4)])  
evaluate_ensemble(X_minmax_tomek, y_minmax_tomek, vt)
```

```
Evaluation:  
recall_score: 0.8787773532476555  
f1_score: 0.873015873015873  
accuracy_score: 0.8587874136607828  
precision_score: 0.8673294480630785
```

0.878

Hasil akhir:

- Hasil visualisasi untuk ekstraksi informasi
- Mengambil model Linear SVM hasil hyperparameter tuning sebagai model akhir

Take Action

Model yang telah dibuat, dapat diserahkan kepada instansi yang lebih berwenang untuk pendeteksian dini pada para penderita depresi

Pengadaan survey berdasarkan fitur yang dimasukkan pada entry model



Pembuatan kebijakan baru untuk menekan angka penderita depresi.

**Thank You for The
Opportunity and
Experience**